

以下是我们在调试 1-MinerU.py 过程中经历的四大核心问题及最终的通关方案汇总：

1. Detectron2 编译与虚拟环境隔离失效

- 症状：直接安装 detectron2 失败；装了 torch 后编译依然报错 ModuleNotFoundError: No module named 'torch'。
- 原因：pip 的环境变量污染导致包被装到了全局路径，且 pip 默认开启了“构建隔离”，导致编译子进程找不到主环境的 torch。
- 解决：全程使用绝对路径（./mineru_env/bin/python3）锁定虚拟环境，并使用 --no-build-isolation 参数强制让 detectron2 使用当前环境已有的 torch 进行编译。

```
./mineru_env/bin/python3 -m pip install torch torchvision  
--force-reinstall
```

```
# 强制在虚拟环境文件夹内运行 detectron2 安装  
./mineru_env/bin/python3 -m pip install  
'git+https://github.com/facebookresearch/detectron2.git'  
--no-build-isolation
```

2. OCR 权重版本断代(幽灵 v3 报错)

- 症状：报错找不到 ch_PP-OCRv3_det_infer.pth。
<https://github.com/opendatalab/MinerU/discussions/3955>
- 原因：ModelScope 上的官方仓库已整体升级至 1.0 版（仅包含 v5 权重），并删除了旧版文件。但 MinerU 某一过渡版本的底层代码在初始化时，依然死板地强制检查 v3 权重的存在（即使通过 lang="ch" 指定使用 v5 也会被前置拦截）。
- 解决：放弃包管理器，直接编写纯 Python 脚本，通过 urllib 从 HuggingFace 镜像源“外科手术式”地下载缺失的几个 v3/v4 权重文件，并精准投放到指定的 paddleocr_torch 目录中。
=> PDF-Extract-Kit_ocrv3_download.py

3. JSON 配置文件格式引发崩溃

- 症状：尝试关闭公式识别时，报错 AttributeError: 'bool' object has no attribute 'get'。
- 原因：新版 MinerU 源码期望 formula-config 是一个包含模型名称和启用状态的字典（Dictionary），而不能直接赋值为 false（Boolean）。
- 解决：撤销了 JSON 中的布尔值配置，恢复默认设置（或使用正确的字典格式关闭该模块）。

Users > kimberleyzhong > {} magic-pdf.json > ...

```
33     "models-dir": "/private/var/ifc/app_data/autodl-tmp/models/modelscope_models/models",
34     "device-mode": "mps",
35     "config_version": "1.3.1",
36     "layoutreader-model-dir": "/private/var/ifc/app_data/autodl-tmp/models/modelscope_models",
37     "layout-config": {
38         "model": "doclayout_yolo"
39     },
40     "formula-config": {
41         "mfd_model": "yolo_v8_mfd",
42         "mfr_model": "unimernet_small",
43         "enable": false
44     }
45 }
```

4. 公式模块与 Transformers 库神仙打架

- 症状: 在最后的 MFR Predict 阶段报错 `TypeError: ... got an unexpected keyword argument 'cache_position'`。
- 原因: 新版 transformers (4.45+) 强行加入了显存优化参数 `cache_position`, 而 MinerU 依赖的公式提取模型 (Unimernet) 代码较老, 无法接收该新参数导致崩溃。
- 解决: 在主脚本 1-MinerU.py 顶部写了一段“拦截补丁 (Monkey Patch)”, 动态劫持 `forward` 方法并在传参前剥离掉 `cache_position`, 成功在不降级依赖的情况下保住了数学公式的完美提取功能。

为什么会连环报错?

1. 关于 `bool` 报错: 在最新的 MinerU 架构中, `formula-config` 必须是一个字典 (Dictionary), 我之前让你填入单纯的 `false`, 导致代码试图调用 `.get()` 方法时崩溃了。这是我的失误!
2. 关于 `cache_position` 报错: 这是 AI 开源界典型的“神仙打架”。MinerU 1.3.x 强行依赖了较新版的 `transformers`, 而新版 `transformers` 在底层生成文本时加入了一个叫 `cache_position` 的新参数, 但 MinerU 内部负责解析公式的 `Unimernet` 模型代码还是老版本, 它不认识这个参数, 一接收到就直接崩溃了。

现在, 我为你提供两个方案。强烈推荐方案一, 既不用降级, 又能完美提取数学公式!

方案一: 加入“魔法补丁” (推荐, 保留数学公式提取)

既然报错是因为底层的 `forward` 方法多收到了一个不认识的参数, 那我们直接用 Python 的动态特性, 写一个拦截器把它“吞掉”!

请打开你的 `1-MinerU.py`, 在顶部的 `import` 区域 (比如 `import os` 和 `import json` 之后), 加入下面这几行代码:

```
Python

import os
import json
from pathlib import Path

# ===== 加入这段魔法补丁 =====
import magic_pdf.model.sub_modules.mfr.unimernet.unimernet_hf.modeling_unimernet

_original_forward = modeling_unimernet.UnimerMBartForCausalLM.forward

def _patched_forward(self, *args, **kwargs):
    kwargs.pop("cache_position", None) # 动态吞掉不兼容的新参数
    return _original_forward(self, *args, **kwargs)

modeling_unimernet.UnimerMBartForCausalLM.forward = _patched_forward
# =====

# 使用magic-pdf本地处理文件
from magic_pdf.data.data_reader_writer import FileBasedDataWriter, FileBasedDataF
# ... 保持你后面的代码不变 ...
```