

做 EDA (Exploratory Data Analysis, 探索性数据分析) 的核心目的, 用一句通俗的话来说就是: “在把数据喂给 AI 模型之前, 先彻底摸透你的数据底细。”

在深度学习 (尤其是像咱们课程里的 YOLO 目标检测项目) 中, 有一句铁律叫 “Garbage in, garbage out” (垃圾进, 垃圾出)。如果不了解数据直接盲目去跑模型, 通常会遇到精度上不去、Loss 不收敛等问题。

结合你之前发的散点图 (Anchor) 和柱状图 (类别分布), 做 EDA 主要有以下 4 个最核心的目的:

1. 发现数据分布问题 (解决“偏科”)

- 目的: 明确数据集中各类别的比例, 判断是否存在类别不均衡 (Class Imbalance)。
- 实际应用: 就像你之前发的那张图, rolled-in_scale 有近 270 个, 而 scratches 只有 60 个。如果不做 EDA, 你可能根本不知道数据比例达到了 4.5:1。模型训练后可能会完全忽略 scratches。
- 后续动作: 一旦 EDA 发现了这个问题, 你就可以决定引入 **Focal Loss** (让模型更关注稀有类别)、或者使用离线数据增强 (给少样本类别做翻转、加噪声) 来拉平数据。

2. 指导模型参数的“量身定制” (如 Anchor 设计)

- 目的: 分析目标的几何特征 (绝对大小、长宽比)。
- 实际应用: 就像你发的那张长宽散点图。如果不做 EDA, YOLO 会使用针对 COCO 数据集 (主要拍人、车、狗等大目标) 的默认 Anchor。但工业质检里的划痕通常是极细、极小的。
- 后续动作: 通过 EDA 画出散点图并使用 K-Means 聚类, 你得到了 [15, 10], [20, 45] 这样专属于你钢铁缺陷的先验框 (Prior Anchors)。把这些参数填进配置文件, 模型一开始就能用最合适的“模板”去抓取缺陷, 精度和收敛速度都会大增。

3. 制定“对症下药”的数据增强策略

- 目的: 发现数据的普遍缺陷和痛点, 决定用什么增强手段。
- 实际应用:
 - EDA 发现目标整体偏小? $\rightarrow$ 必须开启 Mosaic (马赛克, 四图拼接增强)。
 - EDA 发现缺陷的方向随机? $\rightarrow$ 必须开启随机旋转 (Rotation) 和翻转 (Flip)。
 - EDA 发现厂房照片光照不均、对比度差? $\rightarrow$ 需要使用 Albumentations 库做 HSV 色彩扰动或 CLAHE (直方图均衡化)。EDA 决定了你的数据增强不是瞎试, 而是有的放矢。

4. 排查“脏数据”与标注异常 (清洗排雷)

- 目的: 找出错误标注, 防止模型训练崩溃。
- 实际应用: 在 EDA 画图或统计时, 你可能会发现:
 - 某个缺陷框的宽/高居然超过了图片本身的尺寸。
 - 坐标出现了负数。
 - 某张图片里有几千个极小且重叠的框 (可能是标错的噪点)。
- 后续动作: 把这些“脏数据”挑出来删掉或重新标注。如果不清理, 这些离谱的数据会产生极大的异常梯度, 导致模型训练时 Loss 爆炸 (变成 NaN)。

总结来说：

EDA 不是为了训练模型，而是为了 诊断数据。做好了 EDA，你后面的配置修改、数据增强、模型调优等一切工作，就都有了科学依据，而不是靠“炼丹”瞎蒙。