

是的, SVD(奇异值分解)不仅能帮我们进行矩阵分解, 更是确定低秩近似中最佳“秩”(Rank k)的核心数学工具。

它主要通过分析奇异值(Singular Values)的衰减情况来帮助我们做出决定。具体原理如下:

- 奇异值代表信息权重: 在 SVD 分解式 $A = U\Sigma V^T$ 中, 中间的对角矩阵 Σ 包含了所有的奇异值(即你截图中圈出的 16.47, 6.21, 4.40, 2.90, 1.58)。这些值默认是从大到小严格排列的, 数值越大, 代表该维度包含的原始矩阵信息(或方差)越多。
- 观察奇异值衰减断崖(Elbow Method): 通过观察这些奇异值的大小, 你会发现它们通常存在一个“断崖式”的下降趋势。断崖之前的少数几个大奇异值代表了系统的“主成分”(如推荐系统中的主流受众偏好、金融市场中的大盘 Beta 因子), 而后面拖着的一长串小奇异值往往代表着个体特异性细节或纯粹的随机噪声。
- 计算方差占比(能量保留率): 在工程实践中, 我们通常不会凭直觉决定保留几个特征, 而是通过量化计算。将前 k 个奇异值的总和(或平方和)除以所有奇异值的总和, 就能得到一个百分比。例如, 业务上要求保留原始数据 90% 的特征信息, 算法就可以自动推算出刚好满足该阈值的最小秩 k 是多少。

结合你提供的图片来看:

原始评分矩阵经过分解后, 产生了 5 个奇异值。但前两个(16.47 和 6.21)占据了主导地位。讲师为了求近似解, 将特征个数设定为 $k=2$, 直接丢弃了后面的 4.40、2.90 和 1.58 以及它们对应的行列向量。

这样做不仅极大地压缩了数据的存储空间(实现了降维), 而且得到的近似矩阵 A' 过滤掉了原有数据中的稀疏噪声, 依然精准捕捉了用户和物品之间的核心隐性关联。

需要我为你具体计算一下图中前两个奇异值(16.47 和 6.21)到底保留了原始矩阵百分之多少的信息量吗?