

如果不使用 LoRA, 对一个 7B 大小的模型进行全参数微调(**Full Fine-Tuning**), 大约需要 **100GB** 到 **120GB** 的显存。

这意味着单张 24GB 的 RTX 4090 或者 80GB 的 A100 都是远远不够的, 通常需要多张高端专业显卡(如 2-4 张 80GB A100)并配合分布式训练框架(如 DeepSpeed、FSDP)才能跑起来。

我们可以根据课程资料中提供的公式, 一步步拆解这 100GB+ 显存是怎么被吃掉的:

总显存 = 模型权重显存 + 优化器状态显存 + 梯度显存 + 前向传播激活值显存。

1. **模型权重 (Model Weights)**: 7B 模型在 FP16(半精度)下, 大约需要 **14GB** 显存。
2. **梯度 (Gradients)**: 全参数微调意味着你需要更新模型的所有参数, 因此需要为每一个参数计算并保存梯度。在 FP16 下, 这同样需要约 **14GB**。
3. **优化器状态 (Optimizer States)**: 这是吃显存的“隐形大头”。标准微调通常使用 AdamW 优化器, 它需要为每个参数保存两个状态变量(动量和方差), 并且通常为了精度会使用 FP32(单精度)来保存。计算下来: 70亿参数 $\times$ 4字节(FP32) $\times$ 2个状态 $\approx$ **56GB**。
4. **激活值 (Activations)**: 前向传播时产生的中间激活值, 具体取决于你的 Batch Size 和序列长度。根据资料估算, 这部分通常会占到模型权重的 20%-30% 甚至更多, 保守估计需要 **10GB - 20GB**。

合计: **14GB(权重) + 14GB(梯度) + 56GB(优化器) + 15GB(激活值) $\approx$ 99GB**。

正因为直接全参数微调需要极高的计算资源和存储空间, 成本极高, 业界才必须引入 PEFT(如 LoRA)技术。LoRA 通过将可训练的参数量压缩到通常不到 10%, 直接把占用显存最多的“优化器状态”和“梯度”两项砍掉了 90% 以上, 从而让整体微调显存骤降到 19GB 左右, 让 4090 这种消费级显卡也能跑得动大模型。

你需要我为你解释在显存受限(比如只有一张显卡)的情况下, 除了 LoRA, 业界常用的类似 QLoRA 这种 4-bit 量化技术是如何进一步极限压缩显存的吗?