

这是一个非常敏锐的问题！直接回答你的两个疑问：

1. SGLang 不能支持千级并发吗？

恰恰相反，SGLang 不仅支持千级并发，而且在很多场景下，它的并发承载能力和吞吐量比 vLLM 还要强。

课件中强调 vLLM “支持千级并发”，是因为 vLLM 是第一个通过引入 PagedAttention 解决显存浪费问题，从而在业界确立了“高并发生产标准”的先驱框架 。

而 SGLang 是站在 vLLM 的肩膀上诞生的“后起之秀”：

- 它的定位本身就是“更快的 vLLM”，特别适合做高并发、低延迟的 API 服务 。
- SGLang 独创了 RadixAttention(前缀树 KV 复用)技术 。在多轮对话、Agent 等有大量重复系统提示词的场景下，它能极其高效地复用显存，其长上下文吞吐量可以达到 vLLM 的 2-5 倍 。在 H100 单卡上的极限吞吐量测试中，SGLang 也比 vLLM 高出约 29% 。

所以，如果 vLLM 能做到千级并发，SGLang 完全可以做到，甚至在特定场景下能做到“数千级”。

2. “支持千级并发”是指显卡(H100)的并发，还是 vLLM 的并发？

准确地说：它是 vLLM(软件)的能力，成功解锁了 H100(硬件)的潜力。两者缺一不可。

我们可以把“并发能力”拆成硬件和软件两个维度来看：

硬件端(比如 H100 显卡)：提供的是“肌肉”(算力基础)

- H100 拥有 16896 个 CUDA 核心 ，天生就是为了做海量并行矩阵计算而生的 。
- 但是，哪怕 H100 算力再强，如果没有好的软件框架，它也发挥不出来。在 vLLM 出现之前，如果你用原生的 HuggingFace 框架，一张 H100 可能同时处理几十个并发请求就 OOM(显存溢出)崩溃了。这是因为传统的请求级调度会为每个请求粗暴地预留连续的显存，导致显存碎片化严重，70% 的显存被白白浪费 。

软件端(vLLM 框架)：提供的是“大脑”(调度与显存管理)

- vLLM 实现了 软件架构上的突破。它引入的 PagedAttention 像操作系统管理虚拟内存一样，把显存切分成极小的“页(Block)”按需分配，把显存利用率从 30% 硬生生拔高到了 90%+ 。
- 这意味着，原来一张卡只能装下几十个用户的上下文记忆(KV Cache)，现在通过 vLLM 的极致压缩和动态管理，同一张卡可以同时塞下上千个用户的 KV Cache。

总结：

“千级并发”是指作为软件框架的 vLLM(或 SGLang)，具备极其强大的显存统筹和 Token 级动态调度能力。这种软件能力，让底层硬件(H100)的并行算力得以真正释放，从而在系统层面实现了同

时服务上千个请求的壮举。