

这四大主流框架是用于大语言模型(LLM)推理与部署的框架。它们的主要作用是将训练好的 AI 模型高效地运行在硬件(如 GPU/CPU)上,并对外提供服务(如 API 接口)。

根据课件图片和前面的学习资料,这四种框架各自的定位和绝招如下:

- **vLLM**: 目前生产环境最通用的标杆框架。它的核心创新是采用了 PagedAttention(页式 KV Cache 管理),极大地提升了显存利用率,非常适合高吞吐、大并发的线上生产环境。
- **SGLang**: 追求极致性能和长文本优化的新星。它的核心是 RadixAttention(前缀树 KV 复用),在处理多轮对话、Agent(智能体)和 RAG(检索增强生成)等有很多重复前缀(Prompt)的场景时,缓存命中率极高,吞吐量甚至能达到 vLLM 的数倍。
- **TensorRT-LLM**: NVIDIA 官方的极致性能框架。它通过硬件原生优化和自定义 CUDA 核,在英伟达的 GPU 环境下追求极限的推理速度。
- **Ollama**: 主打本地极简部署的工具。它基于 llama.cpp 封装,不需要复杂的环境配置,小白也能在个人电脑(甚至是纯 CPU 或 Mac)上两分钟跑起大模型,非常适合本地开发、边缘设备和快速验证。

简单来说, **Ollama** 适合个人在笔记本上把玩, **vLLM** 适合企业做成标准的 API 服务, **SGLang** 适合做复杂的多轮对话应用, **TensorRT-LLM** 适合在英伟达机房里榨干硬件的每一滴性能。你想深入了解这其中哪一个框架的具体安装或使用细节吗?