

要想在大模型部署中突破现有的并发瓶颈, 达到更大的并发量(例如万级并发或极高吞吐量), 我们需要从**软件架构、模型压缩、硬件横向扩展(Scale-Out)以及纵向升级(Scale-Up)**四个维度来打“组合拳”。

大模型并发的核心底层逻辑是: 并发量 $\approx (\text{GPU 总显存} - \text{模型权重占用显存}) / \text{每个用户请求占用的 KV Cache 显存}$ 。

基于课程资料, 你可以通过以下具体手段来实现更大的并发:

1. 框架与架构层优化(提升调度效率)

- 切换到前缀缓存更优的框架(如 **SGLang**): 如果你的业务场景是多轮对话、Agent 或 RAG (检索增强生成), 这些场景会带有大量重复的系统提示词(Prompt)。使用 SGLang 的 RadixAttention(前缀树 KV 复用)技术, 可以将这些重复内容的缓存复用率提升至 75-95%, 其长上下文吞吐量可以达到 vLLM 的 2-5 倍 。
- **PD 分离架构(Prefill-Decode Disaggregation)**: 现代 LLM 推理引擎(如 vLLM 和 SGLang)正在引入 PD 分离架构 。即将计算密集的“预填充(Prefill)”阶段和访存密集的“解码(Decode)”阶段分开, 交由不同的 GPU 节点处理, 这能大幅降低首 Token 延迟并提升整体并发吞吐 。

2. 模型与显存层优化(给 KV Cache 腾空间)

要服务更多并发用户, 就必须在显存中塞下更多用户的 KV Cache, 因此必须压缩模型本身占用的空间:

- **模型量化(Quantization)**: 将模型权重从 FP16 降低到 INT8 甚至 INT4(如使用 GPTQ 或 AWQ 量化)。例如, 量化可以将模型体积缩小一半以上, 从而腾出海量显存用于接收新的并发请求 。Blackwell 架构的 B200 甚至原生支持 FP4 低精度推理, 内存占用比 FP8 再减 1.8 倍, 吞吐提升 55% 。
- **选择参数量合适的模型**: 不要盲目追求大参数。如果业务场景允许, 使用 7B-9B 级别的小模型(或蒸馏模型)替代 70B 模型, 可以成倍释放显存空间 。

3. 硬件纵向升级(Scale-Up: 单点暴力拉升)

- **升级超大显存 GPU**: 大模型推理的瓶颈在于“内存墙” 。将显卡升级为拥有巨大显存和带宽的型号, 如 H200(141GB 显存 / 4.8TB/s 带宽) 或 B200(192GB 显存 / 8TB/s 带宽) 。单卡显存越大, 能同时承载的并发 KV Cache 就越多。
- **解决 CPU 与系统内存的隐形瓶颈**: 并发量极大时, CPU 的请求调度、Tokenization(分词)以及前后处理会导致 GPU 陷入饥饿等待 。必须保证每 1 张 GPU 配比 16-32 核 CPU 和 512GB-1TB 的系统内存(DRAM) 。

4. 硬件横向扩展(**Scale-Out**: 集群化部署)

- 张量并行(**Tensor Parallelism**): 在 vLLM 等框架中通过 `--tensor-parallel-size` 参数 , 将一个大模型切分到多张 GPU 上运行。这不仅能利用多卡的聚合显存带宽加速计算, 还能分摊模型权重占用的显存, 从而让集群整体能接纳更多并发。
- 多实例负载均衡: 在物理机集群前增加负载均衡器(如 Nginx 或专用的 API 网关), 同时启动多个 vLLM/SGLang 实例。当单个实例的千级并发达到极限时, 将流量横向分发到成百上千张 GPU 组成的集群中。