

这张图片展示的是推测解码 (Speculative Decoding) 流程闭环的最后一个环节: **Step 3: Draft Model** (小模型) 基于最新纠正的结果, 开启新一轮的草稿生成。

我们继续沿着 Step 1 和 Step 2 的**“学生写草稿, 老师批考卷”**的比喻往下讲:

背景回顾 (Step 1 & 2 发生了什么)

- **学生 (小模型)** 之前交的草稿是: [jumps, over, the, lazy]。
- **老师 (大模型)** 批改后发现, 前三个词对了, 但第四个词错了。于是老师把 "lazy" 划掉, 改成了 "dog"。
- 现在黑板上 (最终确定的输出) 的正确句子是: "The quick brown fox **jumps over the dog**"

举例说明 Step 3 (开启新一轮循环)

在这个步骤中, 系统要把老师给出的“标准答案”重新喂给学生, 让学生继续往下写。

1. 同步最新状态 (同步答案)
 - 系统对小模型说: “上一轮你最后猜的 lazy 错了, 大模型老师给的正确答案是 **dog**。现在你要基于 [... jumps over the dog] 这个全新的、绝对正确的上下文, 继续往下猜。”
 - 这就是图片中, 箭头从红色的 "dog" 重新指回蓝色方块 "Draft model" 的含义。
2. 小模型重新开始狂奔 (生成新草稿)
 - 小模型接收到了 "dog", 立刻开启了下一轮的“自回归预测”。
 - 它可能会迅速且连续地猜出接下来的 4 个词, 比如: [**and, runs, away, quickly**]。
3. 进入下一个 **Step 2** (循环往复)
 - 小模型把这 4 个新猜的词打包, 再次交上去给大模型老师“批阅”。
 - 大模型再用一次并行计算, 瞬间判定这 4 个词对不对.....

总结 Step 3 的核心意义

Step 3 说明了推测解码是一个**生生不息的循环 (Loop)** 过程。

一旦大模型在验证阶段发生了拒绝 (**Reject**) 并纠错, 整个流程就会把大模型纠正后的那个词 (比如图中的 "dog") 作为新的起点, 打回去给小模型, 让小模型在正确的轨道上继续往下狂奔猜测。两者就这样无缝配合, 直到整篇文章生成完毕。