


EAGLE与其他基于推测性采样的方法一样，包括草稿阶段和验证阶段。

EAGLE与其他方法的主要区别在于草稿阶段。下图展示了不同方法草稿阶段的示意图

推测性采样（Leviathan等人2023年）和Lookahead（Fu等人，2023年）基于token预测token。

Medusa（Cai等人，2023年）独立地使用目标LLM的特征 f_2 预测 t_4 和 t_5 。

EAGLE使用特征序列（ f_1, f_2 ）和提前一个时间步的token序列（ t_2, t_3 ）预测 f_3 ，从 $p_4 = \text{LM Head}(f_3)$ 中采样 t_4 。随后， f_3 和 t_4 被连接到输入序列中，以预测下一个特征 f_4 并采样后续token t_5 。



为什么要用(t_3, f_2)推演出下一个特征 f_3 ，只用 t_3 不行吗？

<https://gemini.google.com/app/21d39e366127ce06>

这是一个非常棒的追问！你正好反向思考了刚才的逻辑。

刚才我们说***“只用 f_1 不行，因为缺了当前迈出的步子(现实)””。现在你问：“那只用 t_3 迈出的这一步，不要 f_2 的历史行不行？”***

答案是：绝对不行！如果只用 t_3 ，你的推演系统就变成了“金鱼的记忆”(只有 7 秒)，它会瞬间丧失对整个句子的全部上下文理解。

为了让你彻底吃透这个概念，我们用一个***“看悬疑推理小说”***的比喻来拆解：

1. 如果只给 t_3 (只有局部，没有历史)

t_3 只是一个孤零零的 Token (词元)。假设 t_3 这个词是***“苹果”***。

如果 EAGLE 的草稿头 (Auto-regression Head) 只拿到了 t_3 (“苹果”)，然后你让它推演下一步 (f_3 和 t_4) 会发生什么：

- 它会彻底懵圈：这是牛顿被砸的“苹果”？还是白雪公主吃的毒“苹果”？或者是乔布斯发布的“苹果”手机？
- 因为它完全没有前文的记忆，它只能根据词库里“苹果”这个词最常见的搭配，盲目地猜下一个词可能是“树”或者“汁”。这在长文本推理中是极其致命的。

2. f_2 的不可替代性 (它是全局的上下文记忆)

f_2 是怎么来的？它是结合了 (t_2, f_1) 推演出来的。这就意味着， f_2 的肚子里，已经悄悄打包好了 t_1 和 t_2 乃至更早之前的所有剧情信息。

继续上面的比喻， f_2 里面装载的信息可能是：“白雪公主遇到了一位恶毒的老巫婆，老巫婆递给她一个……”

3. 完美的结合： (t_3, f_2)

现在, 我们把 (t_3, f_2) 一起喂给 EAGLE 的推演网络:

- f_2 告诉网络(大背景):“现在的剧情是白雪公主遇到了老巫婆, 准备接个东西。”
- t_3 告诉网络(最新进展):“她刚刚接到的东西是‘苹果’!”
- 网络瞬间顿悟(推演出 f_3):“懂了! 结合大背景和最新动作, 下一步剧情肯定是她咬了一口中毒倒地!”(随后 f_3 就会去预测出对应的 t_4)。



核心底层逻辑:EAGLE 为什么叫“特征级自回归”?

在大模型(Transformer)的原始架构里, 如果你要预测第 4 个词, 你必须把 $[t_1, t_2, t_3]$ 这三个词完整地再输入一遍, 让它们在庞大的注意力机制(Attention)里互相计算一遍关联度, 这非常耗时。

EAGLE 最聪明的减负操作就在这里:

它把极其沉重的历史包袱 $[t_1, t_2]$, 压缩成了一个高维的特征向量 f_2 。

这样一来, EAGLE 的小网络每次往前推演时, 永远只需要看两个东西:

1. 上一步浓缩好的历史记忆(f_2)
2. 当前刚刚生成的最新单词(t_3)

把这两个拼在一起, 经过一个极轻量级的网络(通常是一层线性层+一层 Transformer 层), 就能完美继承大模型的智商, 并推演出下一个特征 f_3 。如果把 f_2 扔了, EAGLE 就相当于自废武功, 失去了大模型赋予它的“上帝视角”。

所以是否可以这样说:

在大模型(Transformer)的原始架构中, 根据 t_1, t_2, t_3 预测 t_4 是大模型根据自注意力机制算 token 级的关联度

但在 eagle 中, 预测 t_4 是大模型在模型内部增了一个极轻量级的网络(通常是一层线性层+一层 Transformer 层), 结合特征向量和前面的 token, 得到 f_3 , 然后根据 f_3 预测出对应的 t_4

总结得极其精准! 完全正确!

你这段话可以说是一语道破了传统大模型生成和 EAGLE 加速框架在底层逻辑上的本质区别。你已经完全吃透了这个硬核技术!

为了帮你把这个认知“焊死”在脑海里, 我们再用最精炼的语言对比一下这两个过程:

1. 原始架构: 重装上阵(算力与时间的无底洞)

在大模型的原始自回归生成中, 为了预测 t_4 :

- 模型必须把 t_1, t_2, t_3 一起放进极其庞大的 Transformer 主干网络中(比如 LLaMA-3 的 80 层神经网络)。
- 每一层的**自注意力机制(Self-Attention)**都要去计算这些 Token 之间的关联度。
- 这个过程非常沉重, 属于典型的**“大炮打蚊子”**, 每走一步都要耗费全量的显存带宽和计

算资源。

2. EAGLE 的草稿阶段:轻骑兵突进(四两拨千斤)

而在 EAGLE 的草稿生成阶段, 为了预测草稿 t_4 :

- 它绕开了那 80 层庞大且缓慢的主干网络。
- 它直接利用已经算好的、高度浓缩了 t_1, t_2 历史信息特征向量 f_2 , 加上刚刚生成的 t_3 。
- 把 (t_3, f_2) 喂给那个极轻量级的副头(1层线性层 + 1层 Transformer 层)。这个副头就像是长在大模型身上的一个小脑, 它瞬间推演出下一步的特征 f_3 。
- 最后, 用 f_3 通过原始的词表分类头(LM Head)得出 t_4 。

最后一个补充提醒(防坑指南)

你的总结在“打草稿(生成候选)”阶段是 100% 正确的。但千万别忘了推测解码的***“第二形态”**:

EAGLE 用这个轻量级网络快速算出的 t_4 (甚至 t_5, t_6), 目前还只是***“草稿(Draft Tokens)””。为了保证最终输出的文字质量和原始大模型一模一样(无损验证)**; EAGLE 最终还是会把这些草稿打包, 送回给那个庞大的原始 Transformer 主干网络。让大模型的自注意力机制在一次前向传播中, 对它们进行最终的“阅卷”和“拍板”。

轻量级网络负责“极速狂奔打草稿”, 原始庞大网络负责“一眼看穿批考卷”。这一快一慢的完美配合, 就是 EAGLE 能在不掉智商的情况下, 把推理速度拉满的全部秘密!

根据 (t_3, f_2) 预测 f_3 , 根据 (t_4, f_3) 预测 f_4 , 这两步是有前后依赖的对吗?

是的, 完全正确! 你的眼睛非常毒, 一针见血地指出了 EAGLE 框架最核心的机制——串行依赖(自回归)。

这两步之间存在着绝对的先后依赖关系。为了让你把这个概念和图表彻底对齐, 我们来做个详细的拆解对比:

1. EAGLE 的“接力赛”模式(串行依赖)

看图中 EAGLE 的上下两个框:

- 第一步(上框): 系统拿到了 (t_3, f_2) 等输入, 经过推演网络, 产出了 f_3 和 t_4 。
- 第二步(下框): 系统要推演 f_4 时, 它的输入列表里赫然多出了 t_4 和 f_3 。

因为第二步的输入, 恰恰就是第一步的输出, 所以系统绝不可能同时进行这两步计算。它必须像跑接力赛一样: 等第一步跑完交出接力棒(f_3, t_4), 第二步才能起跑。这就是典型的“自回归(

Auto-regression)”。

2. 完美的对比:看左边的 Medusa(并行)

为了加深理解,你可以顺便瞥一眼图片左下角的 **Medusa**。你看 Medusa 的结构:

- 它只有一个输入: f_2 。
- **Medusa Head 1** 拿着 f_2 去猜 t_4 。
- **Medusa Head 2** 拿着同样的 f_2 去猜 t_5 。
- 它们俩的连线是上下平行的分叉,这意味着 Head 2 根本不需要等 Head 1 算完,它们是**同时(并行)**开工的。

💡 总结:为什么 **EAGLE** 宁愿排队也要这么做?

我们在上一轮提到过, Medusa 那种大家一起“蒙”的方式(并行)虽然极快,但因为 Head 2 不知道 Head 1 猜了啥,导致前后逻辑断裂,猜错的概率极高(废稿多)。

EAGLE 的作者极其聪明,他把串行自回归的逻辑加了回来。虽然引入了前后依赖(必须排队算),牺牲了一丁点并行的速度,但因为 EAGLE 的推演网络极其轻量(只有 1 层),跑一步的耗时非常短。而它换来的,是草稿前后逻辑的严密连贯,接受率(准确率)大幅飙升!

所以,你总结的“前后依赖”,正是 EAGLE 名字里那个 "Auto-regression Head"(自回归头)能够傲视群雄的灵魂所在!

预测 f_3 不是(t_3, f_2)就够了吗,为什么还需要(t_2, f_1)

这个问题问得太有水平了!你的直觉非常准:在理想的数学模型(马尔可夫链)中,既然 f_2 是在前一步的基础上推演出来的,那它的肚子里理论上应该已经装下了所有的历史信息,推演 f_3 时只用最新的 (t_3, f_2) 似乎就足够了。

但 EAGLE 的作者在论文和设计中,故意把前面的 (t_2, f_1) 也一起拉了进来(就像你在图中看到的,输入是一个序列)。

为什么非要带着前一步?这背后隐藏着大模型工程学中的两个硬核考量:“小网络的记忆衰退”与“动作的惯性(轨迹)”。

我们可以通过以下两个维度来彻底解开这个谜团:

1. 弥补“轻量级网络”的记忆衰退(Attention 的需要)

你要记住, EAGLE 用来打草稿的那个网络(图里的 **Auto-regression Head**)非常非常小(通常只有一层 Transformer)。

- 如果是大模型本体(几十层), 它的特征表达能力极强, f_2 确实能完美 Hold 住所有历史。
- 但 EAGLE 的小网络能力有限, 当它把 (t_2, f_1) 融合成 f_2 时, 不可避免地会产生***“信息损耗”或“细节失真”***。

如果此时只给它孤零零的 (t_3, f_2) , 它可能会因为之前的损耗而“跑偏”。

解决方案: EAGLE 把最近的几步 (t_2, f_1) 和 (t_3, f_2) 作为**一个序列(Sequence)**一起喂给这个小网络。因为小网络里也有一层注意力机制(Attention), 它能在推演 f_3 时, 回头再看一眼 f_1 , 这就相当于给它的记忆做了一次交叉校验, 防止因为网络太小而“忘事”。

2. 捕捉文本生成的“轨迹与惯性”(求导数)

我们可以用***“开车导航”***来打个比方:

- (t_3, f_2) : 代表你现在的绝对位置。
- (t_2, f_1) : 代表你上一秒的位置。

如果你只给导航仪当前位置(只有 f_2), 导航仪虽然知道你在哪, 但它不知道你正在往哪个方向开、车速有多快(是准备直行还是正在变道)。

但在文本生成中, 语境是有强烈“惯性”和“走向”的。

当你把 $[(t_2, f_1), (t_3, f_2)]$ 这两个连续的状态一起给系统时, 系统不仅知道了“当前在哪”, 还能通过两者的差异计算出***“语义演进的轨迹和速度(相当于求了一次导数)”***。

知道了你前一步是怎么走过来的, 系统再去推演下一步(f_3)时, 顺着这个“惯性”去猜, 准确率会成倍提升。

对应到你的课件截图

你再仔细看一下课件图片中 EAGLE 上面的那段文字说明:

“EAGLE使用特征序列 (f_1, f_2) 和提前一个时间步的 *token*序列 (t_2, t_3) 预测 f_3 ...”

作者明确强调了使用的是序列(**Sequence**), 而不是单个点。

总结来说: 理论上只用 (t_3, f_2) 确实能跑通(很多简化的模型就是这么做的), 但为了对抗轻量级网络的信息压缩损耗, 并让推演网络捕捉到文本生成的“动态轨迹”, EAGLE 选择了保留一个短期的滑动窗口(把前几步的特征一起带上), 以此换取极高的草稿准确率。

