

Typical Acceptance理解

Thinking: 假设模型正在生成句子, 当前要预测"The weather today is"后面的词:

模型预测分布:

"sunny" →  $p=0.35$ , 信息量 $=-\log(0.35)=1.51$

"good" →  $p=0.25$ , 信息量 $=-\log(0.25)=2.00$

"nice" →  $p=0.20$ , 信息量 $=-\log(0.20)=2.32$

"cold" →  $p=0.10$ , 信息量 $=-\log(0.10)=3.32$

"banana" →  $p=0.001$ , 信息量 $=-\log(0.001)=9.97$

熵  $H = 2.1$  (当前分布的平均不确定性)

Typical Acceptance 的判断:

| 候选 token | 信息量  | 与熵H的距离            | 判定                |
|----------|------|-------------------|-------------------|
| "sunny"  | 1.51 | $ 1.51-2.1 =0.59$ | 接受 (接近熵)          |
| "good"   | 2.00 | $ 2.00-2.1 =0.10$ | 接受 (非常接近)         |
| "nice"   | 2.32 | $ 2.32-2.1 =0.22$ | 接受 (接近熵)          |
| "cold"   | 3.32 | $ 3.32-2.1 =1.22$ | 拒绝 (偏 surprising) |
| "banana" | 9.97 | $ 9.97-2.1 =7.87$ | 拒绝 (太 surprising) |

温度高 → 接受阈值更宽松 → 更多候选被接受 → 解码更快, 但质量可能下降

温度低 → 接受阈值更严格 → 只接受最"典型"的 → 质量更高, 但速度慢

| 候选词的惊吓度 - 当前语境的平均预期惊吓度 | < 预设阈值, 这种方式为什么可以解决以下问题:

大模型的概率分布可能会随着“温度(Temperature)”等参数波动, 导致小模型很难精准踩中那个绝对概率最高的词, 草稿被频繁打回, 加速效果大打折扣。<https://gemini.google.com/app/21d39e366127ce06>

这是一个极其深刻且直击大模型采样理论核心的问题!

要理解这个公式为什么能解决“温度(Temperature)”波动导致的草稿频繁被打回的问题, 我们可以用一个核心概念来概括: 它把“绝对的固定靶”变成了一把“水涨船高的相对标尺”。

我们通过三个层次来彻底扒开它背后的数学与逻辑原理:

## 1. 温度(Temperature)是如何搞破坏的?

首先, 我们要知道调节“温度”在底层到底改变了什么。

- 低温(如  $T=0.1$ ): 概率分布变得极其尖锐。最高的概率可能高达 90%, 其他的全是 0.001%。
- 高温(如  $T=1.5$ ): 概率分布会被“压平”。原本 90% 的可能掉到了 30%, 原本 1% 的可能升到了 5%。

传统验证的死穴(绝对标准):

如果大模型使用传统的推测解码验证(要求草稿词必须是概率最高的那一个, 或者概率必须大于某个固定绝对值, 比如  $P > 20\%$ )。

当用户把温度调高, 整个分布被压平了, 原本绝对概率最高的词, 其概率也会大幅度下降。此时小模型辛辛苦苦猜中了一个词, 但大模型一看: “哎呀, 在现在的温度下, 它的绝对概率只有 15%, 不合格, 打回!” —— 这就导致了小模型很难精准踩中动态变化的高概率基准线, 加速效果大跌。

---

## 2. 这个公式的魔法：“水涨船高”的相对抵消

Typical Acceptance 公式： $|I(x) - H(P)| < \epsilon$

它之所以能免疫温度的干扰，是因为公式等号左边的两项（候选词的惊吓度  $I(x)$ ，和当前语境的平均惊吓度/熵  $H(P)$ ），它们受到温度的影响是同向且同步的！

- 当\*\*温度调高（分布变平）\*\*时：
  - 大模型对未来的不确定性增加了  $\rightarrow$  算出来的平均惊吓度  $H(P)$  变大了。
  - 同时，由于所有高频词的绝对概率都被稀释了，候选词  $x$  的概率  $P(x)$  也会变小  $\rightarrow$  算出来的该词的惊吓度  $I(x)$  也跟着变大了。

发现了吗？水涨（熵变大），船也高（单个词的信息量也变大）！

虽然绝对数值都在剧烈变化，但它们之间的差值（相对距离）却保持了高度稳定。

🧠 数值模拟演示：

假设小模型猜了词  $X$ ：

- 在常温下 ( $T=1.0$ )：大模型算出的熵  $H(P) = 2.0$ 。词  $X$  的概率是 25%，其惊吓度  $I(x) = 2.0$ 。
  - 代入公式： $|2.0 - 2.0| = 0 < \epsilon$ （完美接受）
- 在高温下 ( $T=1.5$ )：分布被压平了。大模型算出的熵  $H(P)$  飙升到了 **4.0**。同时，词  $X$  的概率被稀释到了 6%，它的惊吓度  $I(x)$  也飙升到了 **4.06**。
  - 代入公式： $|4.06 - 4.0| = 0.06 < \epsilon$ （依然完美接受！）

无论温度怎么变，大模型看重的不再是“你的概率有多高”，而是\*\*“你的概率与我当前的迷茫程度是否匹配”\*\*。

---

## 3. 从“射击靶心”到“射击圆环” (Typical Set 典型集)

除了抵消温度变化，这个公式还解决了一个概率学上的痛点：大模型本身就不总是想输出概率最高的那一个词。

在信息论中，有一个概念叫\*\*“典型集”(Typical Set)\*\*。

- 如果你只接受概率最高的词 (Argmax)，那就像是要求小模型每次必须正中靶心(10环)。这极其困难，一旦偏一点就是 0 分 (打回重写)。
- 而 Typical Acceptance 公式，实际上是在大模型的概率分布中画出了一个\*\*“环形的舒适区”

💡 最终结论

这个公式通过\*\*“相对距离（信息量与熵的差值）”取代了“绝对概率的大小”\*\*。这不仅让它自带了对抗温度、Top-p 等采样参数波动的“免疫力”，还大大拓宽了小模型容错的范围，使得草稿被接受的概率大幅飙升，从而真正保住了推测解码的极致加速效果。