

这是一个非常敏锐且直击本质的好问题！很多刚接触 GPU 性能监控的人都会产生这种疑惑。

直接回答你的问题:显存(VRAM)绝对是 GPU 物理硬件中不可或缺的一部分。

你之所以会产生这个疑问,是因为在日常交流和很多监控工具(比如最常用的 nvidia-smi 命令)中,“GPU 利用率”和“显存占用率”是被严格拆分成两个独立指标来看待的。

我们来拆解一下幻灯片里这句“GPU 利用率低,显存占满但计算未满足”到底是什么意思。

你可以把整个 GPU 想象成一家超级工厂,它主要由两个核心部分组成:

1. 显存(VRAM - 仓库):负责存放数据(模型权重、输入的内容、KV Cache 等)。对应监控里的 **Memory Usage**(显存占用率)。
2. 计算单元(CUDA Cores / Tensor Cores - 生产线上的工人):负责执行真正的数学矩阵运算。对应监控里的 **GPU-Util / Volatile GPU-Util**(这也就是图中说的“GPU 利用率”)。

为什么会出现“显存占满,但 GPU 利用率低”?

在大语言模型(LLM)推理时,特别是幻灯片里提到的**“seq_len(序列长度)过长”**的场景下,会发生以下情况:

1. 仓库爆仓(显存占满):当用户输入的上下文(seq_len)非常长时,模型为了记住这些上下文,会生成极其庞大的 KV Cache(中间计算结果缓存)。这些缓存数据非常占空间,瞬间就把 GPU 的“显存仓库”塞得满满当当。
2. 无法接新单(并发上不去):因为仓库全满了,工厂(GPU)就无法再接收新的并行任务(也就是无法增加 Batch Size)。
3. 工人闲置(计算未满足/GPU利用率低):既然并行任务少,需要做的矩阵乘法计算量其实就不够大。计算单元(工人)算得非常快,他们很快把手头的算完了,然后就只能停下来干等(等下一批极长的数据从显存慢吞吞地搬运过来)。

总结

图中说的**“GPU 利用率低(<50%)”,特指的是计算单元(算力)处于闲置、吃不饱的状态;而导致它们吃不饱的原因,恰恰是因为 GPU 的显存空间**被极长的文本缓存占满了,成为了木桶效应里最短的那块板。

这就是典型的 **Memory-Bound**(内存墙/访存瓶颈),算力被存储空间给拖累了。所以右侧给出的解决思路(比如量化 fp8 省显存,或者开启动态预填充),核心都是为了腾出显存空间,好让并发量上去,最终把闲置的计算单元给喂饱。